## 参考示例 1:

单步调试 Faster R-CNN 算法

train\_net.py

首先读取 cfg 参数:

args = default\_argument\_parser().parse\_args()

```
will args = {Namespace} Namespace(config_file=',configstCOCO-Detection/faster_rcnn_R_50_FPN_1x.yami', dist_uri='tcp://127.0.0.1:49152', eval_only=False, machine_rank=0, num_gpus=1, num_machir... view is config_file = (st)* ',configstCoCO-Detection/faster_rcnn_R_50_FPN_1x.yami' is dist_uri='tcp://127.0.0.1:49152', eval_only=False, machine_rank=0, num_gpus=1, num_machir... view is dist_uri='tcp://127.0.0.1:49152', eval_only=False, num_gpus=1, num_gpus=
```

```
© g = (Criphode: 12) CUDNN, BENCHMARK: Falsen/DATALOADER:In ASPECT_RATIO_GROUPING: True!n FILTER_EMPTY_ANNOTATIONS: True!n NUM_WORKERS: 0jn REPEAT_THRESHOLD: 0.0\n SAMPLER - Vie B DEPRECATED_KEYS = (bit) '_deprecated_keys_'

I IMMUTABLE = (str) '_immutable_'

IN REM_ALLOWED = (str) '_new_allowed_'

REMANDE_KEYS = (str) '_immutable_'

IN YEASION = (int) 2

'MODEL' = (Criphode: 22) ANCHOR_GENERATOR:in ANGLES: [[-90, 0, 90]]in ASPECT_RATIOS: [[0.5, 1.0, 2.0]]in NAME: DefaultAnchorGeneratorin OFFSET: 0.0\n SIZES: [[32], [64], [128], [256], [512]]in Vie Criphode: 22) ANCHOR_GENERATOR:in ANGLES: [[-90, 0, 90]]in TYPE: relative_rangeln/FORMAT: BGRI:MASK_FORMAT: polygori/mMAX_SIZE_TEST: 1333/:MAX_SIZE_TRAIN: 1333/:MMIN_SIZE_TEST: 800V

'OATASETS' = (Criphode: 8) CROP:\(\text{in}\) ENECOMPUTED_PROPOSAL_TOK_TEST: 1000/:\(\text{in}\) ENECOMPUTED_PROPOSAL_TOK_TEST: 1000/:\(\text{in}\) ENECOMPUTED_PROPOSAL_TILES_TEST: (\text{in}\) FROM COLDER (Criphode: 8) ASSEC_TEATO, GROUPING: True!n/TILETE_EMPTY_ANNOTATIONS: True!n/TILETE_ENT_THRESHOOD. 0.0\n/SAMPLER_TRAIN: TrainingSampler

'SOLVER' = (Criphode: 8) ASSEC_TEATO, GROUPING: True!n/TILETE_EMPTY_ANNOTATIONS: True!n/TILETE_ENT_THRESHOOD. 0.0\n/SAMPLER_TRAIN: TrainingSampler

'SOLVER' = (Criphode: 8) ASSEC_TEATO, GROUPING: True!n/TILETE_EMPTY_ANNOTATIONS: True!n/TILETE_ENT_THRESHOOD. 0.0\n/SAMPLER_TRAIN: TrainingSampler

'SOLVER' = (Criphode: 8) ASSEC_TEATO, GROUPING: True!n/TILETE_EMPTY_ANNOTATIONS: True!n/TILETE_ENT_THRESHOOD. 0.0\n/SAMPLER_TRAIN: TrainingSampler

'SOLVER' = (Criphode: 8) AUG-IN ENABLED: Falsein FLIP: True!n MAX_SIZE: 4000\n/ Nin SIZES: (400, 500, 600, 700, 800, 900, 1000, 1100, 1200)\n/DETECTIONS_PER_MAGE: 100\n/PEVAL_PERIOD: 0\n/PEVAL_PERIOD: 0\n/PEVAL_PER
```

进入 Trainer 函数, defaults.py 文件中 275、276、277 为模型构建、优化器构建、数据读取构建部分:

| 274 | # Assume these objects must be constructed in t       |
|-----|---|
| 275 | model = self.build_model(cfg)                         |
| 276 | optimizer = self.build_optimizer(cfg, model)          |
| 277 | <pre>data_loader = self.build_train_loader(cfg)</pre> |

## 模型构建部分:

#### 特征提取网络

resnet.py

210:bottom\_up = build\_resnet\_backbone(cfg,input\_shape) # 建立 resnet 的 backbone, 此处选用 resnet50, 根据代码可知: 它包括四组 bottleneck, 每组分别为 3, 4, 6, 3 个, 每组里的具体结构如下所示, 用于提取语义信息。

```
| T_destination = (TypeVar) = (TypeVar) = T_destination = (TypeVar) = (TypeVar) = T_destination = (TypeVar) =
```

211: in\_features = ['res2', 'res3', 'res4', 'res5']#fpn 的输入特征,即采用 resnet 的 此 4 个卷积组中的特征图, 组内特征图大小相同, 组间递减。

fpn.py

213: 建立 FPN 网络结构,它主要包括自下而上网络、自上而下网络、横向连接与卷积融合四个部分得到输出。 自下而上结构采用 resnet50 中的 res2,res3,res4,res5 各组中的特征图作为输入,输入通道数依次为 256, 512, 1024, 2048, 经 1\*1 卷积降低通道数使输出通道数为固定的 256, 自上而下的对特征图上采样(最近邻插值),从而进行特征图的融合,而后经 3\*3 卷积对融合后的特征图再融合,这样可以消除上采样带来的重叠效应,从而生成最终的特征图即检测层,好处是使用 FPN 方法融合了不同层的特征,较好地改善了多尺度检测问题。

#### RPN 模块

rpn.py

201: in\_features = ['p2', 'p3', 'p4', 'p5', 'p6'] #输入 5 个检测层。

202: self.rpn head = head #定义 rpn 的 head, 用于提取特征, 单步调试时可

看到 anchor\_deltas 和 objectness\_logits 中的 12 和 3,从而可知每个特征点铺设了三个锚框。

203: self.anchor\_generator = anchor\_generator #定义生成 anchor 的函数, 4 个通道。

204: self.anchor\_matcher = anchor\_matcher #定义对 标签和 anchor 进行匹配的函数,可知 iou<0.3 时为负样本, iou>0.7 时为正样本。

```
anchor_matcher = {Matcher} <detectron2.mo
allow_low_quality_matches = {bool} True
labels = {list: 3} [0, -1, 1]
thresholds = {list: 4} [-inf, 0.3, 0.7, inf]</pre>
```

205: self.box2box\_transform = box2box\_transform #定义对 anchor 和 ground truth 求取回归的真值函数。

#### Fast-RCNN 模块

roi\_heads.py

525: in\_features = ['p2', 'p3', 'p4', 'p5']#输入的特征, Rol Pooling 模块接受卷积网络提取的特征图和对应的 RPN 的 Rol, 此处指卷积网络提取的 4 种特征图。

```
> i box_in_features = {list: 4} ['p2', 'p3', 'p4', 'p5']

oi 0 = {str} 'p2'

oi 1 = {str} 'p3'

oi 2 = {str} 'p4'

oi 3 = {str} 'p5'

oi _len_ = {int} 4
```

526: box\_pooler = ROIPooler((level\_poolers): ModuleList(

- (0): ROIAlign(output\_size=(7, 7), spatial\_scale=0.25, sampling\_ratio=0, aligned=True)
- (1): ROIAlign(output\_size=(7, 7), spatial\_scale=0.125, sampling\_ratio=0, aligned=True)
- (2): ROIAlign(output\_size=(7, 7), spatial\_scale=0.0625, sampling\_ratio=0, aligned=True)
- (3): ROIAlign(output\_size=(7, 7), spatial\_scale=0.03125, sampling\_ratio=0, aligned=True)
- ))#到 Rol Pooling 阶段,将 RPN 产生的不同维度特征变换到相同维度,满足后续全连接神经网络要求,此处应是用 Rol Align 实现此操作,最终得到固定 7\*7 大小区域的特征。

527: box\_head = FastRCNNConvFCHead(

(fc1): Linear(in\_features=12544, out\_features=1024, bias=True)

(fc2): Linear(in\_features=1024, out\_features=1024, bias=True))

此处指每个 Rol 经池化后得到固定维度为 256\*7\*7=12544 的特征, 经全连接神经网络得到长度为 1024 的 Rol 特征。

528: box\_predictor = FastRCNNOutputLayers(

(cls\_score): Linear(in\_features=1024, out\_features=81, bias=True)

(bbox\_pred): Linear(in\_features=1024, out\_features=320, bias=True)

```
box_predictor = {FastRCNNOutputLayers} FastRCNNOutputLayers(\n (cis_score): Linear(in_features=1024, out_features=81, bias=True)

I __destination = {TypeVar} ~T_destination

bbox_pred = {Linear} Linear(in_features=1024, out_features=320, bias=True)

box2box_transform = {Box2BoxTransform} < detectron2.modeling.box_regression.Box2BoxTransform object at 0x7f8c4c1f64e0>

box_reg_loss_type = {str} 'smooth_l1'

cis_score = {Linear} Linear(in_features=1024, out_features=81, bias=True)

dump_patches = {bool} False

loss_weight = {dict: 1} {'loss_box_reg': 1.0}

smooth_l1_beta = {float} 0.0

test_nms_thresh = {float} 0.5

test_score_thresh = {float} 0.05

test_topk_per_image = {int} 100

training = {bool} True
```

在此有 80 类物体+1 类背景, 因此分类网络输出维度应为 81; 回归网络预测的输出维度为 80\*4。

rcnn.py(整个 faster-rcnn 的框架)

58: #此处为 Fast-RCNN 的 backbone, 即 resnet50+FPN, 如下图所示:

```
    □ backbone = (FM); FPN(n (fpn_lateral2); Conv2d(256, 256, kernel_size=(1, 1), stride=(1, 1))n (fpn_output2); Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))n (fpn_lateral3); Conv2d(1... View dump_patches | (norm); FrozenBatchNorm2d(num_features=64, ... View dump_patches | (bool) false | (norm); FrozenBatchNorm2d(num_features=64, ... View dump_patches | (conv2d); Conv2d(256, 256, kernel_size=(1, 1), stride=(1, 1)) |
    □ fpn_lateral3 = (Conv2d); Conv2d(256, 256, kernel_size=(1, 1), stride=(1, 1)) |
    □ fpn_lateral3 = (Conv2d); Conv2d(256, 256, kernel_size=(1, 1), stride=(1, 1)) |
    □ fpn_lateral3 = (Conv2d); Conv2d(256, 256, kernel_size=(1, 1), stride=(1, 1)) |
    □ fpn_lateral3 = (Conv2d); Conv2d(256, 256, kernel_size=(1, 1), stride=(1, 1)) |
    □ fpn_lateral3 = (Conv2d); Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1)) |
    □ fpn_lateral3 = (Conv2d); Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1)) |
    □ fpn_lateral3 = (Conv2d); Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1)) |
    □ fpn_lateral3 = (Conv2d); Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1)) |
    □ fpn_lateral3 = (Conv2d); Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1)) |
    □ fpn_lateral3 = (Conv2d); Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1)) |
    □ fpn_lateral3 = (Conv2d); Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1)) |
    □ fpn_lateral3 = (Conv2d); Conv2d(256, 256, kernel_size=(1, 1), stride=(1, 1), conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), con
```

# 59: RPN 定义生成 proposal, 结构如下图所示:

60: Faster-RCNN 第二阶段定义, ROIAlign 后输出大小都为 7\*7, 如下图所

#### 示:

```
□ rol_heads = (StandardROlHeads) StandardROlHeads) (In (box_pooler): ROlPooler(in (level_poolers): ModuleList(in (0): ROlAlign(output_size=(7, 7), spatial_scale=0.25, sampling_ratio=0, aligned=True... Vio □ box_head = (FishRChNConvFCHead) FastRChNConvFCHead(in (fc1): Linear(in_features=12544, out_features=1024, bias=True)(in (fc2): Linear(in_features=1024, bias=True)(in (fc2): Linear(in
```

## 模型训练部分:

- 5) dataset dict.py
- 121: 读入图片及一些必要信息, 如下图所示:

数据增广,此处的处理是短边到 400,长边不大于 1333 等,如下图所示:

157: 对数据增广后的图片相应的标注进行处理。

185: 得到处理好的图片和标注。

train\_loop.py

### 读入要进行处理的图片及数据

## rcnn.py 151:#对输入数据先进行前处理

```
images = [x["image"].to(self.device) for x in batched_inputs] x: {'file_name
images = [(x - self.pixel_mean) / self.pixel_std for x in images]
images = ImageList.from_tensors(images, self.backbone.size_divisibility)
return images
```

rpn.py: ResNet 和 FPN 特征提取得到五个检测层,该图片的检测层如下图所示:

#### 牛成. anchor:

```
grid_sizes = [feature_map.shape[-2:] for feature_map in features]
anchors_over_all_feature_maps = self._grid_anchors(grid_sizes)
return [Boxes(x) for x in anchors_over_all_feature_maps]
```

## 5 个检测层生成 5 个对应的 anchor:

```
\[ \frac{1}{2} \f
```

## 把特征输入 rpn 网络预测锚框的类别和偏差预测的锚框的偏差:

```
      V ≡ pred_anchor_deltas = {list: 5} [tensorl[[[-3.5765e-03, -4.4666e-02, -8.1669e-02, ..., -1.2866e-01,n]
      -2.6367e-02, -1.1915e-01],n [4.4634e-02, -6.7971e-02, -2.0510e-01, ..., -8.5940e-03,n]
      -9.185e-02, -1.915e-01],n [4.4634e-02, -6.7971e-02, -2.0510e-01, ..., -8.5940e-03,n]
      -9.185e-02, -1.915e-01],n [4.4634e-02, -6.7971e-02, -2.0510e-01, ..., -8.5940e-03,n]
      -9.185e-02, -1.915e-01],n [4.4634e-02, -6.7971e-02, -2.0510e-01, ..., -8.5940e-03,n]
      -9.5764e-03,n]
      -9.5764e-03,n]
```

#### 预测的锚框的类别:

#### 将锚框与真实标注匹配. 锚框的真实类别:

```
v i gt_labels = {list: 1} [tensor([-1, -1, -1, ..., -1, -1], device='cuda:0', dtype=torch.int8)]
> = 0 = {Tensor: 63195} tensor([-1, -1, -1, ..., -1, -1], device='cuda:0', dtype=torch.int8)
o __len__ = {int} 1
```

根据锚框真实偏差、真实类别和预测偏差、预测类别可以算 loss, 根据代码可知回归用 smooth l1 loss, 分类用 cross entropy。

448: 用 NMS 生成 1000 个 proposal 做进一步的分类与回归得到 proposal:

roi\_heads.py 661: 把 proposal 和真实标注混合得到正负样本并得到最终的 Rol 便于求第二阶段的分类和回归, 经 Rol Pooling 得到相同维度 7\*7 的特征 rcnn.py 对候选区域分类和回归预测经损失函数得到 4 个 losses,则一张图片处理完成。

至此, 对一张图片前传训练完成, 而后进行反传。

Training 过程:

构建模型: build\_model(cfg)、build\_optimizer(cfg, model)、build\_train\_loader(cfg)。

迭代过程: train\_loop: run\_step()——>rcnn.py: forward()

图片预处理: rcnn: forward(): self.precess\_image()

rcnn.py: forward(): 返回四个 losses: 二分类+回归 & rpn 的多分类+回归

# 参考示例 2:

训练程序从 train\_net.py 开始,首先读入配置文件参数 args, main 函数中读入 所有参数 cfg。

然后跳转到 Trainer 函数。

首先是 Trainer 的初始化过程:

初始化过程包括构建模型、优化器、数据读取三个部分,对应函数分别为build\_model(cfg), build\_optimizer(cfg, model), build\_train\_loader(cfg)。

build\_model(cfg)函数:

build\_model 包括构建 backbone、proposal 生成、构建 roi\_heads 三个主要函数。

1. build\_backbone(cfg)函数:

首先构建 resnet\_backbone, 对应函数为 build\_resnet\_backbone(cfg, input\_shape),构建 resnet\_backbone 包括从配置文件中读取 resnet 深度,out\_features 等,以及从默认 cfg 文件中读取 resnet 默认设置参数,最终返回 resnet model。

接着构建 FPN 模块,构建 fpn 模块使用 FPN 类来构建,输入参数包括 bottom\_up(resnet50 模型), in\_features (res2, res3, res4, res5), out\_channels(256) 等,构建 fpn 时使用横向连接卷积和上采样卷积完成。最终 out\_features 为[p2, p3, p4, p5, p6]五个层,每层的通道数为 256。最后返回 FPN 模块。

2. bulid\_proposal\_generator(cfg, backbone.output\_shape())函数:

包括构建 rpn 网络和计算 rpn loss 两个主要内容。

# 构建 rpn:

其中 rpn 构建使用 RPN 类来完成,利用 cfg 设置 rpn 的输入特征 in\_features 为[res2, res3, res4, res5], nms 阈值为 0.7,正样本阈值 0.5,训练和测试时的 proposal 最大数量 (训练 2000,测试 1000)等参数。之后使用 build\_anchor\_generator 构建 5 个特征层上的 anchor。五个特征层上的 anchor 尺寸为[32, 64, 128, 256, 512],同时长宽比使用[0.5, 1, 2]来生成 3 个长宽比的 anchor,利用不同特征图的 h 和 w 和下采样 stride 倍数,来 shift 生成整个特征图的 anchor。

接着使用 Box2BoxTransfrom 来构建坐标转换类,其中包括成员函数 get\_deltas 为计算预测 box 和 target box 的偏差值(dx, dy, dw, dh), 计算公式为 Faster R-CNN 论文中的偏差归一化计算公式。构建 anchor 匹配类 Matcher, Matcher 的输入参数为 iou 阈值 (0.3, 0.7), 匹配时每个 gt 的最大 iou 的 anchor 为正样本,iou 大于 0.7 的 anchor 为正样本,小于 0.3 的为负样本,中间区间的为忽略样本。最后构建 rpn\_head 模块,包括一个 3x3 特征增强卷积和两路 1x1卷积,一路用于 rpn 分类预测,一路用于 rpn 回归预测。

3. bulid roi heads(cfg, backbone.output shape())函数

初始化构建包括 box\_head、box\_pooler、box\_predictor 三个模块构建。Box\_head 包含两个全连接层(7\*7\*256 -> 1024, 1024 -> 1024)。box\_pooler 为 roi\_pooling 或 roi\_align 模块,代码中构建 4 个 roi\_align 模块分别对应从[p2, p3, p4, p5] 上扣取特征。Box\_predictor 包含两个全连接层(1024 -> 81, 1024 -> 320),分别负责类别预测和坐标回归。

build\_optimizer(cfg, model)函数:

包括初始学习率的设置, weight\_decay 设置, 模型参数 params 的 weight 和 bias 中学习率和 weight\_decay 的设置, 优化器的设置 (SGD)。

build\_train\_loader(cfg)函数:

构建训练数据集,包括数据预处理(几何变换、光学变换等(程序中使用 Resize 和 HFlip)),并将数据集转换为 pytorch 的 data\_loader 形式。

完成 Trainer 的初始化构建后,开始进入训练过程,主要使用 run\_step()函数来完成:

run\_step()函数

完成 Trainer 的构建后, 进入 run\_step()函数开始训练。

首先使用 data = next(data\_loader)迭代器来读取数据,接着 data 进入之前构建的 model 开始训练过程:

- 1. 首先对 data 进行预处理(均值方差归一化,数据增强变换等)
- 2. data 进入 backbone 提取特征。首先经过 resnet 得到[res2, res3, res4, res5] 的特征, 然后经过 FPN 模块得到[p2, p3, p4, p5, p6]的特征。
- 3. 调用 proposal\_generator 函数生成 proposals 和 proposal\_loss。proposals 的生成定义在 RPN\_outputs 类中,包括 anchor 的匹配,正负样本划分,分类与回归 loss 的计算等)
- 4. 将 proposal 送入 roi\_heads 网络得到 roi\_head\_loss。
- 5. loss 更新 proposal\_loss 和 roi\_head\_loss。
- 6. 返回 loss, 退出 model 的 forward 函数。

返回至 run\_step 函数,对 loss 字典的 4 种 loss 求和。

然后进行 pytorch 训练的 4 步经典过程 (计算 loss, 优化器梯度清 0, loss 反

# 传, 优化器单次优化)

losses = sum (losses)

optimizer.zero\_grad()

losses.backward()

optimizer.step()

一步训练完成后。train\_loop.py 文件中的 train () 函数循环调用 run\_step()函数 完成训练的迭代,最终完成模型的训练。

# 训练 Faster R-CNN\_R50\_FPN

训练环境: ubuntu18.04, 1 块 GTX 1080Ti 显卡

训练集: coco\_2017\_trian, 测试集 coco\_2017\_val

训练参数:

batch\_size: 2

由于使用单卡训练, 因此修改 iter、Ir 这两个参数。

将 max\_iter 由 90000 变为 720000, 相应的 step\_iter 由 (60000, 80000) 变为 (480000, 640000), Ir 由 0.02 变为 0.0025。

# 训练结果:

单卡训练总时间: 57 小时

模型精度: ap: 38.03 ap50: 59.14 aps: 22.71 apm: 41.36 apl: 49.08

官方精度: ap: 37.93 ap50: 58.84 aps: 22.44 apm: 41.14 apl: 49.10

训练结果与官方结果相比基本相同。